

다회검정 문제와 다층모형

Why We (Usually) Don't Have to Worry About Multiple Comparisons

Gelman, Hill, & Yajima (2012)

Journal of Research on Educational Effectiveness, 5: 189–211

강의 노트

용어 안내

본 강의자료에서는 **다회검정 (multiple comparisons; 多回檢定)** 을 표준 용어로 사용한다. 한국 통계학회에서 통용되는 “**다중비교**” 또한 같은 의미로 사용되는 용어이며, 두 표현은 본 자료에서 동의어로 취급한다.

왜 “다회검정”인가? 문제의 본질은 하나의 데이터셋(또는 하나의 연구)에 대해 검정을 여러 번 반복하기 때문에 누적 오류율이 부풀어 오른다는 것이다. 한자 “다중(多重)”의 “겹쳐 누적된”이라는 뜻은 이 현상을 잘 잡지 못한다 — 빈도주의 검정들은 서로 겹치는 것이 아니라 단순히 여러 번 수행될 뿐이다. 이에 비해 “다회(多回)”의 “여러 차례”라는 뜻이 본질을 더 정확히 포착한다. 다만 “다중비교”/“다중검정”이 학계에서 표준 용어로 굳어져 있으므로, 학생들은 두 표현 모두에 익숙해질 필요가 있다.

Contents

1 왜 이 논문을 읽어야 하는가	1
2 빈도주의 관점에서 본 다회검정 문제 (IHDP 8개 사이트)	2
2.1 데이터와 모형	2
2.2 사이트별 개별 검정	2
2.3 Bonferroni 보정	2
2.4 FDR (Benjamini-Hochberg)	2
3 다른 관점: Type S, Type M error	2
4 베이지안 다층(Hierarchical) 모형	4
4.1 모형 정의	4
4.2 Pooling의 세 가지 양상	4
4.3 Shrinkage의 대수적 유도	4
5 예제 1: Eight Schools (Rubin 1981)	5
5.1 실제 데이터	5
5.2 세 가지 분석의 비교	5
5.3 Stan 모형 코드 (주력 MCMC 도구)	5
5.4 NumPyro 버전 (보조 도구)	7
6 예제 2: IHDP 8개 사이트 시뮬레이션	7
6.1 Stan 모형 코드	8

7 결론과 권고	8
7.1 빈도주의자가 자주 하는 실수 모음	10
7.2 언제 다층모형이 가장 유용한가	10
8 연습문제	10

1 왜 이 논문을 읽어야 하는가

수많은 가설을 한꺼번에 검정하는 상황은 거의 모든 응용 통계에서 나타난다. 8개 학교에서의 처치 효과, 50개 주의 평균 점수, 1,000명의 교사 효과, 100개 유전자의 발현 차이 등.

전통적인 빈도주의 해법은 **p-value**를 조정하는 것이다.

- Bonferroni: $\alpha' = \alpha/k$
- Sidak: $\alpha' = 1 - (1 - \alpha)^{1/k}$
- Benjamini-Hochberg (FDR)

이 모든 방법은 Type 1 error, 즉 “실제로는 효과가 없는데 있다고 잘못 결론짓는 비율”을 통제하는 데 초점이 맞춰져 있다.

핵심 아이디어

Gelman 등은 다음과 같이 주장한다:

1. Type 1 error는 진짜 효과가 정확히 0이라는 가정 위에 서 있다. 사회과학·교육학·정책평가에서 이 가정은 거의 항상 틀렸다.
2. 진짜 걱정해야 할 것은 **Type S** (sign — 부호를 거꾸로 추정) 과 **Type M** (magnitude — 효과 크기를 과대 추정) 오류이다.
3. 이 모든 문제는 베이지안 다층(hierarchical) 모형으로 자연스럽게 다룰 수 있다. Bonferroni처럼 신뢰구간을 인위적으로 넓히는 대신, 다층모형은 추정치들을 서로 끌어당긴다(shrinkage).

2 빈도주의 관점에서 본 다회검정 문제 (IHDP 8개 사이트)

2.1 데이터와 모형

Infant Health and Development Program (IHDP)는 미국 8개 사이트에서 저체중·미숙아에게 가정방문과 양질의 보육 서비스를 제공한 무작위 통제 실험이다. 각 사이트별로 처치 효과가 동일한지 다른지를 알고 싶다.

학생 i 의 검사 점수 y_i 를 다음과 같이 모형화한다:

$$y_i = \sum_{j=1}^8 (\gamma_j S_i^j + \delta_j S_i^j P_i) + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, \sigma^2) \quad (1)$$

여기서 S_i^j 는 사이트 j 에 속하는지를 가리키는 더미, P_i 는 처치 여부(0/1), γ_j 는 사이트 j 의 통제군 평균, δ_j 는 사이트 j 의 처치 효과이다.

2.2 사이트별 개별 검정

가설 $H_0^j: \delta_j = 0$ 을 $j = 1, \dots, 8$ 에 대해 각각 검정한다. 유의수준 $\alpha = 0.05$ 일 때 독립을 가정하면, 8번 검정 중 적어도 1번이 H_0 을 잘못 기각할 확률은

$$1 - (1 - 0.05)^8 \approx 0.34.$$

이것이 **family-wise error rate (FWER)**가 부풀어 오르는 문제이다.

2.3 Bonferroni 보정

각 검정의 임계값을 $\alpha/k = 0.05/8 \approx 0.00625$ 로 낮춘다. 등가적으로 신뢰구간의 폭을 $z_{1-\alpha/(2k)} \approx 2.73$ 으로 넓힌다 (기준 1.96 대비).

빈도주의가 자주 빠지는 함정

Bonferroni는 Type 1 error를 직접 통제하지만, 그 대가로 Type 2 error(power 손실)가 크게 증가한다. 표본 크기가 작거나 효과가 작은 사이트는 진짜 효과가 있어도 발견할 수 없게 된다.

2.4 FDR (Benjamini-Hochberg)

“기각된 가설들 중 잘못 기각된 비율”(false discovery rate)을 통제하는 방법. 유전체학 등에서 유용하지만, 사회과학에서는 여전히 “효과가 정확히 0”이라는 출발점에 의존하므로 한계가 있다.

3 다른 관점: Type S, Type M error

Gelman & Tuerlinckx (2000)은 Type 1 / Type 2 대신 다음을 제안한다:

- **Type S (sign) error**: 진짜 효과가 양수인데 “음의 효과가 있다”고 결론.
- **Type M (magnitude) error**: 진짜 효과가 작는데, 유의한 추정치는 진짜 효과의 몇 배 크기로 부풀려진다.

낮은 power(큰 SE)일수록 “유의”로 살아남은 결과는 더 극단적인 값일 수밖에 없다 — 이른바 statistical significance filter.

빈도주의가 자주 빠지는 함정

빈도주의가 자주 하는 결정적 실수

“유의하면 효과가 있는 것이고, 유의하지 않으면 효과가 없는 것이다.” — 이것은 틀린 명제다. 저전력 연구에서 “유의함”은 그 자체로 **과대 추정의 증거**이며, “유의하지 않음”은 **정보 부족의 증거**일 뿐이다.

4 베이지안 다층(Hierarchical) 모형

4.1 모형 정의

이제 식 (1)을 다음과 같이 확장한다:

$$y_i \sim \mathcal{N}(\gamma_{j[i]} + \delta_{j[i]} P_i, \sigma_y^2) \quad (2)$$

$$\gamma_j \sim \mathcal{N}(\mu_\gamma, \sigma_\gamma^2) \quad (3)$$

$$\delta_j \sim \mathcal{N}(\mu_\delta, \sigma_\delta^2) \quad \leftarrow \text{핵심} \quad (4)$$




Figure 1: 두 sampling distribution. 진짜 효과가 0인데도, SE가 큰 경우(파란 곡선) “유의”로 판정되는 결과는 진짜 효과로부터 크게 떨어진 값일 가능성이 높다.




Figure 2: 시뮬레이션: 진짜 효과 = 2일 때 SE의 함수로 본 power, Type S, Type M. SE가 커질수록 Type S/M 모두 폭증한다.

이 한 줄이 모든 것을 바꾼다. 사이트별 처치 효과 δ_j 를 서로 독립이 아닌, 공통의 분포에서 나온 값들로 본다. σ_δ 가 작을수록 “사이트들의 효과는 사실 비슷하다”는 뜻이고, 큰 값일수록 “사이트별로 효과가 매우 다르다”는 뜻이다.

4.2 Pooling의 세 가지 양상

- **Complete pooling:** 모든 $\delta_j = \delta$ ($\sigma_\delta \rightarrow 0$ 의 극한)
- **No pooling:** 사이트별로 독립적 추정 ($\sigma_\delta \rightarrow \infty$ 의 극한; 빈도주의의 출발점)
- **Partial pooling:** 둘 사이의 데이터-주도 절충. σ_δ 를 데이터에서 추정.

4.3 Shrinkage의 대수적 유도

가장 간단한 정규-정규 hierarchical model:

$$\bar{y}_j \mid \theta_j \sim \mathcal{N}(\theta_j, \sigma_y^2), \quad \theta_j \sim \mathcal{N}(\mu, \sigma_\theta^2).$$

μ, σ_θ 가 알려져 있을 때, θ_j 의 사후분포는 (conjugate)

$$\mathbb{E}[\theta_j | \bar{y}_j] = w_j \bar{y}_j + (1 - w_j) \mu, \quad (5)$$

$$\text{Var}(\theta_j | \bar{y}_j) = \frac{1}{1/\sigma_\theta^2 + 1/\sigma_{\bar{y}}^2}, \quad (6)$$

$$w_j = \frac{\sigma_\theta^2}{\sigma_\theta^2 + \sigma_{\bar{y}}^2} \quad (\text{shrinkage weight}). \quad (7)$$

- $\sigma_{\bar{y}}^2 \ll \sigma_\theta^2$: $w_j \rightarrow 1$, “개별 추정 거의 그대로 신뢰”.
- $\sigma_{\bar{y}}^2 \gg \sigma_\theta^2$: $w_j \rightarrow 0$, “공통 평균 μ 로 강하게 끌어당김”.

두 그룹 차이 $\theta_j - \theta_k$ 의 z-score:

$$z_{\text{MLM}} = \underbrace{\frac{\bar{y}_j - \bar{y}_k}{\sqrt{2} \sigma_{\bar{y}}}}_{z_{\text{classical}}} \cdot \frac{1}{\sqrt{1 + \sigma_{\bar{y}}^2 / \sigma_\theta^2}}. \quad (8)$$

두 번째 인자는 항상 1 이하이고, $\sigma_\theta \rightarrow 0$ 이면 0이 된다.




Figure 3: z-score의 shrinkage 양 (논문 Figure 4 재현).

핵심 아이디어

다층모형은 “얼마나 다회검정을 보정해야 하는가?” 라는 질문에 **데이터가 직접 답하도록 한다**. σ_δ 를 데이터에서 추정하여, “그룹들이 사실 비슷하다”면 자동으로 강한 shrinkage를 적용한다. 별도의 ad-hoc p-value 조작은 필요 없다.

5 예제 1: Eight Schools (Rubin 1981)

5.1 실제 데이터

뉴저지의 8개 고등학교에서 진행된 SAT-Verbal 코칭 효과 메타분석.

School	y_j (point est.)	σ_j (SE)	Bayes M	Bayes SD
A	28	15	11	8
B	8	10	7	6
C	-3	16	6	8
D	7	11	7	7
E	-1	9	5	6
F	1	11	6	7
G	18	10	10	7
H	12	18	8	8

(원 논문 Table 1. 첫 두 열은 원자료, 마지막 두 열은 베이지안 사후 평균/SD.)

5.2 세 가지 분석의 비교




Figure 4: Eight Schools의 세 가지 분석. (A) 사이트별 95% CI, (B) Bonferroni 보정, (C) 베이지안 다층모형. 학교 A (28)와 학교 C (-3)는 사후 평균이 각각 11과 6으로 가까워졌다.

5.3 Stan 모형 코드 (주력 MCMC 도구)

본 강의의 주력 MCMC 샘플러는 **Stan (cmdstanpy)**이다. 비중심 매개변수화 (non-centered parameterization)를 사용해 τ 가 작을 때 funnel 병리를 피한다.




Figure 5: 각 학교에 대해 raw 추정치 y_j (왼쪽) 에서 사후 평균 $\hat{\theta}_j$ (오른쪽) 로 향하는 화살표. 평균에서 멀리 떨어진 학교일수록 더 많이 끌려간다.




Figure 6: 학교 간 진짜 효과의 SD τ 에 대한 사후분포. 0 부근에 상당한 질량이 있다.

eight_schools_nc.stan

```
data {
  int<lower=1> J;
  vector[J] y;
  vector<lower=0>[J] sigma;
}
parameters {
  real mu;
  real<lower=0> tau;
  vector[J] eta;
}
transformed parameters {
  vector[J] theta = mu + tau * eta;
}
model {
  mu ~ normal(0, 10);
  tau ~ normal(0, 10);
  eta ~ std_normal();
  y ~ normal(theta, sigma);
}
```

5.4 NumPyro 버전 (보조 도구)

같은 모형을 NumPyro로 표현하면 다음과 같다. JAX 기반의 빠른 NUTS이며, C++ 툴체인이 필요 없다.

01_eight_schools_numpyro.py (발췌)

```
def eight_schools_model(sigma, y=None):
    mu = numpyro.sample("mu", dist.Normal(0., 10.))
    tau = numpyro.sample("tau", dist.HalfNormal(10.))
    with numpyro.plate("school", J):
        eta = numpyro.sample("eta", dist.Normal(0., 1.))
        theta = numpyro.deterministic("theta", mu + tau*eta)
        numpyro.sample("y", dist.Normal(theta, sigma), obs=y)

kernel = NUTS(eight_schools_model, target_accept_prob=0.95)
mcmc = MCMC(kernel, num_warmup=1000, num_samples=2000, num_chains=4)
mcmc.run(rng_key, sigma, y=y)
```

두 구현은 동일한 NUTS 알고리즘을 사용하며 사후분포 또한 사실상 일치한다. Stan은 사실상의 표준이고 진단/요약 도구가 풍부하다. NumPyro는 Python 환경에서 빠르고 GPU/TPU 활용이 용이하다.

6 예제 2: IHDP 8개 사이트 시뮬레이션

IHDP 원자료를 재배포할 수 없으므로 같은 구조의 데이터를 시뮬레이션한다. 사이트 8개, 사이트당 학생 80명, 진짜 효과의 평균 8.0, 사이트 간 SD 1.2.

Reproduction of Gelman, Hill, Yajima (2012), Figure 1
(IHDP-like simulated data; $J = 8$ sites)




Figure 7: IHDP 시뮬레이션의 세 패널 (논문 Figure 1 재현). (A) 사이트별 OLS, (B) Bonferroni, (C) Stan 다층모형. 다층모형이 점 추정치 자체를 공통 평균 부근으로 끌어당겨 안정적인 결론을 준다.




Figure 8: IHDP 시뮬레이션에서 각 사이트의 raw OLS 추정치(왼쪽)와 Stan 사후 평균(오른쪽).

6.1 Stan 모형 코드

ihdp_multilevel.stan (핵심)

```
data {
  int<lower=1> N;
  int<lower=1> J;
  array[N] int<lower=1, upper=J> site;
  vector[N] P;
  vector[N] y;
}
parameters {
  real mu_gamma, mu_delta;
  real<lower=0> sigma_gamma, sigma_delta, sigma_y;
  vector[J] gamma_raw, delta_raw;
}
transformed parameters {
  vector[J] gamma = mu_gamma + sigma_gamma * gamma_raw;
  vector[J] delta = mu_delta + sigma_delta * delta_raw;
}
model {
  // priors omitted for brevity
  vector[N] mu_i;
  for (i in 1:N) mu_i[i] = gamma[site[i]] + delta[site[i]] * P[i];
  y ~ normal(mu_i, sigma_y);
}
```




Figure 9: IHDP 시뮬레이션에서 σ_δ 의 사후분포 (Stan). 빨간 점선은 진짜 SD (1.2).

7 결론과 권고

핵심 아이디어

Gelman, Hill, & Yajima (2012)의 메시지

1. Type 1 error 패러다임은 사회과학·교육·정책 평가에서 적절한 출발점이 아니다.
2. 진짜 위험은 Type S와 Type M이며, 둘 다 저전력에서 폭증한다. Bonferroni는 power를 떨어뜨려 이 문제를 악화시킨다.
3. 다층모형은 다회검정 보정을 모델 안에 내재화한다. 그룹 간 변동 σ_δ 를 데이터에서 배우므로, 그룹들이 사실 비슷하다면 자동으로 강한 shrinkage를 적용한다.
4. Stein paradox에 의해, 다층모형의 점 추정치는 OLS보다 더 작은 MSE를 가진다.

7.1 빈도주의자가 자주 하는 실수 모음

빈도주의가 자주 빠지는 함정

1. “8개 사이트에 8번의 t-검정을 따로 한 뒤 유의 표시.”
정답: 사이트들을 함께 다층모형으로 적합.
2. “유의하지 않으니 효과가 없다.”
정답: “유의하지 않음”은 “SE가 컸다”는 뜻일 뿐.
3. “유의했으니 효과가 추정값만큼 크다.”
정답: 저전력 상황의 “유의”는 거의 항상 과대 추정 (Type M).
4. “Bonferroni를 적용하면 안전하다.”
정답: Type 1만 통제. Type 2/S/M은 모두 악화.
5. “각 그룹이 다르므로 pooling은 하면 안 된다.”
정답: 다층모형은 그룹이 얼마나 다른지 자체를 데이터에서 추정.

7.2 언제 다층모형이 가장 유용한가

- 그룹 수 J 가 5 이상이고 각 그룹의 데이터가 비교적 작아 잡음이 큰 경우.

- 그룹들이 교환 가능 (exchangeable) 하다고 볼 수 있는 경우.
- 그룹 수준 공변량 (x_j) 이 있다면 더욱 좋다 ($\delta_j \sim \mathcal{N}(\mu_0 + \beta x_j, \sigma_\delta^2)$ 로 확장).

8 연습문제

연습문제

(1) **손으로 푸는 shrinkage.** Eight Schools 데이터에서 학교 A ($y_1 = 28, \sigma_1 = 15$)와 학교 C ($y_3 = -3, \sigma_3 = 16$)를 생각하자. $\mu = 8, \tau = 5$ 로 고정되어 있다고 가정할 때, 각 학교의 사후 평균과 사후 표준편차를 손으로 계산하라.

연습문제

(2) **Stan vs NumPyro 비교.** 01_eight_schools_stan.py 와 01_eight_schools_numpyro.py 를 모두 실행하고, 사후 평균과 τ 의 사후 분위수가 일치하는지 비교하라. 어느 쪽이 더 빠르냐? 어느 쪽이 진단 출력이 더 풍부한가?

연습문제

(3) **Bonferroni vs. shrinkage.** 02_ihdp_simulation_stan.py 의 n_per_site=80을 20으로 바꿔서 다시 실행하라. 어느 분석이 더 많이 변하는가? 왜 그런가?

연습문제

(4) **Type M의 실험.** 03_type_s_m_errors.py 의 true_effect 를 0.5, 2, 8로 바꿔가며 실행하라. 효과 크기가 클수록 Type M error는 어떻게 변하는가? 직관적으로 설명하라.

연습문제

(5) **τ 의 prior 의존성.** eight_schools_nc.stan 에서 $\tau \sim \text{Half-Normal}(0, 10)$ 을 $\text{Half-Cauchy}(0, 5)$ 로 바꾸면 사후분포가 어떻게 달라지는가? Gelman (2006) “Prior distributions for variance parameters” 을 참고하라.

참고문헌

- Gelman, A., Hill, J., & Yajima, M. (2012). Why we (usually) don't have to worry about multiple comparisons. *Journal of Research on Educational Effectiveness*, 5(2), 189–211.
- Rubin, D. B. (1981). Estimation in parallel randomized experiments. *Journal of Educational Statistics*, 6, 377–401.
- Gelman, A., & Tuerlinckx, F. (2000). Type S error rates for classical and Bayesian single and multiple comparison procedures. *Computational Statistics*, 15, 373–390.
- Gelman (2006). Prior distributions for variance parameters in hierarchical models. *Bayesian Analysis*, 1, 515–533.
- Carpenter, B. et al. (2017). Stan: A probabilistic programming language. *Journal of Statistical Software*, 76(1).
- Phan, D., Pradhan, N., & Jankowiak, M. (2019). Composable effects for flexible and accelerated probabilistic programming in NumPyro. arXiv:1912.11554.