

다회검정 문제와 다층모형

Why We (Usually) Don't Have to Worry About Multiple Comparisons

Gelman, Hill, & Yajima (2012)

본 강의에서는 **다회검정 (multiple comparisons; 多回檢定)** 을 표준 용어로 사용합니다.

한국 통계학회에서 통용되는 “**다중비교**”도 동일한 의미로 사용됩니다.

왜 “다회검정”인가?

문제의 본질: 하나의 데이터에 검정을 **여러 번 반복**하기 때문에 누적 오류율이 부풀어 오른다.

“다중(多重)”의 “겹쳐 누적된” 뉘앙스는 부정확. “다회(多回)”의 “여러 차례”가 본질을 더 정확히 포착.

다만 “다중비교”/“다중검정”이 학계 표준이므로 두 표현 모두에 익숙해질 것.

문제 제기

문제: 다회검정은 항상 보정해야 할까?

교육·정책 평가에서 매일 나오는 질문:

- 8개 학교에서 진행한 코칭 프로그램, 어느 학교에서 효과?
- 50개 주의 성적 순위, 어느 주가 의미 있게 다른가?
- 1,000명 교사의 효과 추정치, 어떤 교사가 특별히 좋은가?

전통적 빈도주의 답: **p-value**를 보정하라 — Bonferroni, FDR, Sidak, ...

Gelman 등의 답: **문제 자체를 다시 생각**하자.

핵심 주장

1. Type 1 error 패러다임은 사회과학에서 적절한 출발점이 아니다. (“진짜 효과 = 0”이 거의 항상 거짓.)
2. 진짜 위험은 Type S와 Type M error.
3. 다층(hierarchical) 모형은 다회검정 보정을 모델 안에 내재화한다. Ad-hoc한 p-value 조작 불필요.

빈도주의 관점

IHDP 예제 (8개 사이트)

저체중·미숙아에게 가정방문/양질의 보육 서비스 제공. 각 사이트별 처치 효과 δ_j 를 추정.

고전적 모형:

$$y_i = \sum_{j=1}^8 (\gamma_j S_i^j + \delta_j S_i^j P_i) + \varepsilon_i$$

$$\varepsilon_i \sim \mathcal{N}(0, \sigma^2).$$

각 사이트에 대해 $H_0^j : \delta_j = 0$ 을 독립적으로 검정.

Family-Wise Error Rate가 부풀어 오른다


$\alpha = 0.05$ 로 8번 검정:

$$\Pr(\text{적어도 한 번 잘못 기각}) = 1 - 0.95^8 \approx 0.34$$

Bonferroni: 임계값을 $\alpha/k = 0.05/8 = 0.00625$ 로 낮춤
신뢰구간을 $z_{0.99688} \approx 2.73$ 으로 넓힘 (1.96 대비)

IHDP 시뮬레이션 결과

Reproduction of Gelman, Hill, Yajima (2012), Figure 1
(IHDP-like simulated data; $J = 8$ sites)




- (A) 사이트별 OLS는 잡음으로 흩어진다.
- (B) Bonferroni는 폭만 넓히고 점은 그대로.
- (C) 다층모형은 점 자체를 평균 부근으로 끌어당긴다.

Type S & Type M error

Type 1/2 대신: Type S와 Type M


- **Type S** (sign): 진짜 효과의 부호를 거꾸로 추정.
- **Type M** (magnitude): 유의한 추정치가 진짜 효과보다 훨씬 크다.

저전력 (큰 SE) 일수록 “유의”에 살아남은 결과는 더 극단적이 된다.



시뮬레이션: 진짜 효과 = 2

Gelman & Tuerlinckx (2000) -- the dangers of low-powered studies
(true effect = 2; significance threshold = 1.96-SE)



SE가 커질수록 power는 떨어지지만 유의 결과의 부호 오류율과 과대 추정 비율이 폭증.
Bonferroni는 사실상 SE를 더 크게 만든다 → Type S/M을 악화.

빈도주의가 자주 하는 실수

1. “유의하면 효과가 있는 것, 유의하지 않으면 효과가 없는 것이다.”
틀린 명제.
2. “Bonferroni를 적용했으니 안전하다.”
Type 1만 통제. Type 2/S/M은 악화.
3. “8개 사이트는 다 다르니 각자 따로 분석하자.”
다층모형은 사이트가 얼마나 다른지를 데이터에서 결정.

다층모형의 정의와 직관

다층(Hierarchical) 모형

$$y_i \sim \mathcal{N}(\gamma_{j[i]} + \delta_{j[i]} P_i, \sigma_y^2)$$

$$\gamma_j \sim \mathcal{N}(\mu_\gamma, \sigma_\gamma^2)$$

$$\delta_j \sim \mathcal{N}(\mu_\delta, \sigma_\delta^2)$$

이 한 줄이 모든 것을 바꾼다:

- δ_j 들이 공통 분포에서 나왔다고 본다.
- $\sigma_\delta \rightarrow 0$: 사이트는 사실상 같음 (complete pooling)
- $\sigma_\delta \rightarrow \infty$: 사이트는 완전히 다름 (no pooling)
- σ_δ 자체를 데이터에서 추정 $\Rightarrow$ partial pooling

Shrinkage의 대수

가장 간단한 정규-정규 모형:

$$\bar{y}_j \mid \theta_j \sim \mathcal{N}(\theta_j, \sigma_{\bar{y}}^2), \quad \theta_j \sim \mathcal{N}(\mu, \sigma_{\theta}^2).$$


사후 평균:

$$\mathbb{E}[\theta_j \mid \bar{y}_j] = w_j \bar{y}_j + (1 - w_j) \mu, \quad w_j = \frac{\sigma_{\theta}^2}{\sigma_{\theta}^2 + \sigma_{\bar{y}}^2}$$

w_j 가 “개별 정보를 얼마나 믿을지” 결정.

잡음이 크면 ($\sigma_{\bar{y}}$ 큼) $\rightarrow w_j$ 작음 $\rightarrow$ 공통 평균 쪽으로 강하게 끌어당김.

z-score의 shrinkage (논문 Fig. 4)



두 그룹 차이의 z-score는 항상 다음 인자로 감소:

$$Z_{\text{MLM}} = Z_{\text{classical}} \cdot \frac{1}{\sqrt{1 + \sigma_y^2/\sigma_\theta^2}}$$

데이터-주도 다회검정 보정이 자동으로 일어남.

예제 1: Eight Schools

Eight Schools (Rubin 1981) – 실제 데이터


SAT-Verbal 코칭 효과 실험 (뉴저지 8개 고등학교):

School	y_j	σ_j	Bayes M	Bayes SD
A	28	15	11	8
B	8	10	7	6
C	-3	16	6	8
D	7	11	7	7
E	-1	9	5	6
F	1	11	6	7
G	18	10	10	7
H	12	18	8	8

(원 논문 Table 1.)

같은 데이터, 세 가지 시각


Eight Schools (Rubin 1981) — same data, three analyses



(A) raw 95% CI, (B) Bonferroni, (C) Stan 다층모형.


사후 평균이 A=11, C=6으로 서로 가까워졌다.

Shrinkage가 일어나는 모습



극단값 (A=28, G=18)이 가장 많이 끌려간다.

왜 강한 shrinkage? - τ 의 사후분포



τ 의 사후 질량이 0 부근에 집중되어 있음.

⇒ 데이터가 “학교들의 진짜 효과는 별로 안 다르다”라고 말함.

구현: Stan + NumPyro

주력 (primary): Stan / cmdstanpy

- 베이저안 모형링의 사실상 표준
- 풍부한 진단/요약 도구 (Rhat, ESS, divergence check, ...)
- Stan 문법은 모형 정의가 매우 명시적

보조 (auxiliary): NumPyro (JAX 기반)

- C++ 툴체인 없이 순수 파이썬 환경에서 작동
- JIT 컴파일로 빠른 NUTS, GPU/TPU 활용 용이
- Stan과 동일한 NUTS 알고리즘

두 도구의 결과는 (충분한 sample size에서) 사실상 일치.

Stan 모형 (Eight Schools)

```
data {  
  int<lower=1> J;  
  vector[J] y;  
  vector<lower=0>[J] sigma;  
}  
parameters {  
  real mu;  
  real<lower=0> tau;  
  vector[J] eta;  
}  
transformed parameters {  
  vector[J] theta = mu + tau * eta;  
}  
model {  
  mu ~ normal(0, 10);  
  tau ~ normal(0, 10);    // half-normal  
  eta ~ std_normal();  
  y ~ normal(theta, sigma);  
}
```

NumPyro 모형 (같은 Eight Schools)

```
def eight_schools_model(sigma, y=None):
    mu = numpyro.sample("mu", dist.Normal(0., 10.))
    tau = numpyro.sample("tau", dist.HalfNormal(10.))
    with numpyro.plate("school", J):
        eta = numpyro.sample("eta", dist.Normal(0., 1.))
        theta = numpyro.deterministic("theta", mu + tau*eta)
        numpyro.sample("y", dist.Normal(theta, sigma), obs=y)

kernel = NUTS(eight_schools_model, target_accept_prob=0.95)
mcmc = MCMC(kernel, num_warmup=1000, num_samples=2000, num_chains=4)
mcmc.run(rng_key, sigma, y=y)
```


같은 모형, 같은 알고리즘 (NUTS), 같은 결과.

예제 2: IHDP 시뮬레이션

IHDP 시뮬레이션 (8개 사이트, 사이트당 80명)

참 효과: 평균 8.0, SD 1.2 (사이트 간 변동 작음).

Reproduction of Gelman, Hill, Yajima (2012), Figure 1
(IHDP-like simulated data; $J = 8$ sites)



다층모형 (Stan) 이 “작은 OLS 추정치는 잡음일 가능성”을 자동 반영하여 평균 부근으로 끌어당김.

```
parameters {  
  real mu_gamma, mu_delta;  
  real<lower=0> sigma_gamma, sigma_delta, sigma_y;  
  vector[J] gamma_raw, delta_raw;  
}  
transformed parameters {  
  vector[J] gamma = mu_gamma + sigma_gamma * gamma_raw;  
  vector[J] delta = mu_delta + sigma_delta * delta_raw;  
}  
model {  
  // weak half-normal priors on the sigmas  
  gamma_raw ~ std_normal();  
  delta_raw ~ std_normal();  
  vector[N] mu_i;  
  for (i in 1:N) mu_i[i] = gamma[site[i]] + delta[site[i]] * P[i];  
  y ~ normal(mu_i, sigma_y);  
}
```

결론

Gelman, Hill, Yajima (2012)

- 다회검정은 본질적으로 **모형이 부족해서** 생긴다.
- Bonferroni/FDR은 신뢰구간을 넓혀 Type 1을 통제하지만, 그 대가로 Type 2/S/M을 모두 악화.
- 다층모형은 추정치 자체를 끌어당겨 같은 목표를 달성하면서 효과의 부호와 크기에 대한 **더 신뢰할 만한** 추론을 준다.
- 게다가 점추정의 MSE는 OLS보다 더 작다 (**Stein paradox**).

실무 권고: 그룹 비교가 있는 모든 분석에 다층모형을 기본으로 고려.

학생에게 강조할 점 (요약)

1. “유의”와 “효과 있음”은 같지 않다. SE를 항상 함께 보고.
2. 저전력 + 유의 = 과대 추정 + 부호 오류 위험.
3. Bonferroni는 만능 보장이 아니다. 진짜 효과를 못 보게 만들 수 있다.
4. exchangeable 그룹은 항상 다층 우선.
5. τ 의 사후분포를 항상 확인. 거기에 “보정 강도”가 들어 있다.
6. Stan을 우선 사용, NumPyro는 보완. 두 도구 모두 익숙해질 것.

- Gelman, Hill, Yajima (2012). J. Research on Educational Effectiveness, 5: 189–211.
- Rubin (1981). Estimation in parallel randomized experiments. J. Educational Statistics.
- Gelman & Tuerlinckx (2000). Type S error rates. Computational Statistics.
- Gelman (2006). Prior distributions for variance parameters in hierarchical models. Bayesian Analysis.
- Gelman & Hill (2007). Data Analysis Using Regression and Multilevel/Hierarchical Models.
- Carpenter et al. (2017). Stan: A probabilistic programming language. JSS, 76(1).
- Phan, Pradhan, & Jankowiak (2019). NumPyro. arXiv:1912.11554.

질문 환영합니다

감사합니다